

# FM/FFM 概述 [1]

leolinuxer

July 23, 2020

## Contents

<b>1 前置知识</b>	<b>1</b>
1.1 线性回归模型 . . . . .	1
1.2 非负矩阵分解 . . . . .	2
<b>2 FM 模型</b>	<b>2</b>
2.1 FM 模型的方程推导 . . . . .	3
2.2 FM 模型的假设 . . . . .	3
2.3 FM 模型的计算 . . . . .	3
2.4 FM 模型训练 . . . . .	4
2.5 FM 模型总结 . . . . .	4
2.5.1 FM 模型优点 . . . . .	4
2.5.2 线性回归 vs FM . . . . .	5

## 1 前置知识

### 1.1 线性回归模型

线性回归模型如下：

$$y = w_0 + w_1x_1 + w_2x_2 + \cdots + w_nx_n \Rightarrow y = w_0 + \sum_{i=1}^n w_ix_i$$

线性回归模型的假设：

- 特征之间相互独立不相关；
- 特征的作用是可以叠加的；

线性回归模型假设特征之间是相互独立的、不相关的。但在某些场景中，特征之间往往是相关的，而不是相互独立的。比如 < 女性 > 和 < 化妆品 >，< 程序员 > 与 < 计算机类书籍 >，所以需要特征组合。

特征两两组合，得到二阶多项式如下：

$$y = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n w_{ij} x_i x_j$$

其中， $n$  代表样本的特征数量， $x_i$  是第  $i$  个特征的值， $w_0, w_i, w_{ij}$  是模型参数。则组合特征的参数一共有  $n(n-1)/2$  个，任意两个参数是独立的。

## 1.2 非负矩阵分解

非负矩阵：所有元素非负。若  $X$  是非负矩阵，记作  $X \geq 0$ 。


非负矩阵分解：给定一个非负矩阵  $X \geq 0$ ，找到两个非负矩阵  $W \geq 0$  和  $H \geq 0$ ，使得：

$$X \approx WH$$

即将非负矩阵  $X$  分解为两个非负矩阵  $W, H$  的乘积形式，称为非负矩阵分解。

非负矩阵分解的例子如下：

我们把每个 user 表示成一个二维向量，同时把每个 item 表示成一个二维向量，两个向量的点积就是矩阵中 user 对 item 的打分，写成非负矩阵分解形式如下：



特征关系的向量化，则得 FM 模型。

## 2 FM 模型

论文：Factorization Machines

因子分解机模型，即 Factorization Machine Model，简称 FM。

## 2.1 FM 模型的方程推导

上述二阶多项式的二项式参数  $w_{ij}$  可以组成一个**对称矩阵**  $W$ ，那么这个矩阵可以分解为： $W = V^T V$ ， $V$  的第  $j$  列便是第  $j$  维特征的特征向量，即  $W_{ij}$  的每个参数都可以表示为：

$$W_{ij} = \langle V_i, V_j \rangle$$

这就是 FM 的核心思想。

即上述二阶多项式可以写成：

$$y = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j$$

这边是 FM 的方程。其中， $v_i$  是第  $i$  维特征的隐向量，隐向量的长度为  $k$ ，包含  $k$  个描述特征的因子； $\langle \cdot, \cdot \rangle$  代表向量点积，即  $\langle v_i, v_j \rangle = \sum_{f=1}^k v_{i,f} v_{j,f}$ 。

## 2.2 FM 模型的假设

- 特征之间两两相关；
- 特征的作用是可以叠加的；

## 2.3 FM 模型的计算

利用矩阵直观化推导 FM 模型的计算，具体推导如下。

根据 FM 的二阶多项式，扩充后得到如下矩阵：

$\langle v_1, v_1 \rangle x_1 x_1$	$\langle v_1, v_2 \rangle x_1 x_2$	...	$\langle v_1, v_{n-1} \rangle x_1 x_{n-1}$	$\langle v_1, v_n \rangle x_1 x_n$
$\langle v_2, v_1 \rangle x_2 x_1$	$\langle v_2, v_2 \rangle x_2 x_2$	...	$\langle v_2, v_{n-1} \rangle x_2 x_{n-1}$	$\langle v_2, v_n \rangle x_2 x_n$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\langle v_{n-1}, v_1 \rangle x_{n-1} x_1$	$\langle v_{n-1}, v_2 \rangle x_{n-1} x_2$	...	$\langle v_{n-1}, v_{n-1} \rangle x_{n-1} x_{n-1}$	$\langle v_{n-1}, v_n \rangle x_{n-1} x_n$
$\langle v_n, v_1 \rangle x_n x_1$	$\langle v_n, v_2 \rangle x_n x_2$	...	$\langle v_n, v_{n-1} \rangle x_n x_{n-1}$	$\langle v_n, v_n \rangle x_n x_n$

矩阵**上三角**(绿色部分) 的元素之和即为 FM 的二阶部门：

$$\sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j$$

等于矩阵的全部元素之和减去对角线元素之和，再除以二：

$$\sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j = \frac{1}{2} \left( \sum_{i=1}^n \sum_{j=1}^n \langle v_i, v_j \rangle x_i x_j - \sum_{i=1}^n \langle v_i, v_i \rangle x_i x_i \right)$$

FM 模型的二次项化简推导过程如下：

$$\begin{aligned} \sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j &= \frac{1}{2} \left( \sum_{i=1}^n \sum_{j=1}^n \langle v_i, v_j \rangle x_i x_j - \sum_{i=1}^n \langle v_i, v_i \rangle x_i x_i \right) \\ &= \frac{1}{2} \left( \sum_{i=1}^n \sum_{j=1}^n \sum_{f=1}^k v_{i,f} v_{j,f} x_i x_j - \sum_{i=1}^n \sum_{f=1}^k v_{i,f} v_{i,f} x_i x_i \right) \\ &= \frac{1}{2} \sum_{f=1}^k \left[ \left( \sum_{i=1}^n v_{i,f} x_i \right) \left( \sum_{j=1}^n v_{j,f} x_j \right) - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right] \\ &= \frac{1}{2} \sum_{f=1}^k \left[ \left( \sum_{i=1}^n v_{i,f} x_i \right)^2 - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right] \quad (\text{i 和 j 是等价的}) \end{aligned}$$

即 FM 模型方程 (时间复杂度为  $O(kn^2)$ ):

$$y = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j$$

可以转化为 (时间复杂度为  $O(kn)$ ):

$$y = w_0 + \sum_{i=1}^n w_i x_i + \frac{1}{2} \sum_{f=1}^k \left[ \left( \sum_{i=1}^n v_{i,f} x_i \right)^2 - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right]$$

同时，在稀疏数据场景下，很多特征为 0，所以只需要计算非零特征就行，这样可以极大提升计算效率。

## 2.4 FM 模型训练

FM 可以采用随机梯度下降的方法进行训练。

FM 模型各个参数的梯度如下：

$$\frac{\partial \hat{y}(x)}{\partial \theta} = \begin{cases} 1 & \text{if } \theta \text{ is } w_0 \\ x_i & \text{if } \theta \text{ is } w_i \\ x_i \sum_{j=1}^n v_{j,f} x_j - v_{j,f}^2 x_i^2 & \text{if } \theta \text{ is } v_{i,f} \end{cases}$$

## 2.5 FM 模型总结

### 2.5.1 FM 模型优点

- 适用于高度稀疏化的数据场景；
- 具有线性复杂度；

### 2.5.2 线性回归 vs FM

FM 模型由线性回归模型演化出来。二者的最大区别是：线性回归模型的特征独立，而 FM 模型的特征两两相关。

## References

- [1] “Fm 因子分解机模型的原理、推导、代码和应用.” [Online]. Available: <https://zhuanlan.zhihu.com/p/145436595>