Yolo 系列解读 [1]

leolinuxer

August 24, 2020

Contents

1 相关背景

1.1 图像分类和检测

在进入目标检测任务之前首先得学会图像分类任务，这个任务的特点是输入一张图片，输出是它的类别。

- 对于输入图片，我们一般用一个矩阵表示；
- 对于输出结果，我们一般用一个 one-hot vector 表示：$[0, 0, 1, 0, 0, 0]$，哪一维是 1，就代表图片属于哪一类。

检测器和分类器的区别：

- 他们的输入都是 image；
- 分类器的输出是一个 one-hot vector，而检测器的输出是一个框 (Bounding Box)。

1.2 检测器结果的表示方法

在一个图片里面表示一个框，有很多种方法，比如：

- x,y,w,h；
- p1,p2,p3,p4(4 个点坐标)；
- cx,cy,w,h(cx,cy 为中心点坐标)；
- x,y,w,h,angle(还有的目标是有角度的，这时叫做 Rotated Bounding Box)；
- ……

不管用什么形式去表达这个 Bounding Box，检测器模型输出的结果一定是一个 vector，那这个 vector 和分类模型输出的 vector 本质上有什么区别吗？答案是：没有，都是向量而已。只是分类模型输出是 one-shot 向量，检测模型输出是我们标注的结果。

1.3 基于分类模型的检测任务

所以你应该会发现，检测的方法呼之欲出了。那分类模型可以用来做检测吗？当然可以，这时，你可以把检测的任务当做是遍历性的分类任务。

遍历的方法就是用不同尺寸的矩形框，去遍历图像，执行分类任务，专业术语叫做：滑动窗口分类方法。这种方法的精度和遍历是否彻底密切相关，遍历得越精确，检测器的精度就越高。所以这也就带来一个问题就是：检测的耗时非常大。

2 Yolo 系列的思想

2.1 Yolo V0

YOLO 的作者当时是这么想的：你分类器输出一个 one-hot vector，那我把它换成 (x,y,w,h,c)，c 表示 confidence 置信度，把问题转化成一个回归问题，直接回归出 Bounding Box 的位置不就好了吗？**本质上都是矩阵映射到向量，只是代表的意义不一样而已**。

那如何组织训练呢？找到足够的训练集，把 label 设置为 $(1, x^*, y^*, w^*, h^*)$，这里 x^* 代表真值。有了数据和 label，就完成了设计。

我们会发现，这种方法比刚才的滑动窗口分类方法简单太多了。这一版的思路我把它叫做 YOLO v0，因为它是 You Only Look Once 最简单的版本。

2.2 Yolo V1

但是 YOLO v0 只能输出一个目标，如何识别个多目标呢?

你可能会回答：我输出 N 个向量不就行了吗？但具体输出多少个合适呢？这个 N 又该如何调整呢？答案是：为了保证所有目标都被检测到，我们应该输出尽量多的目标。

比如将图片设置为 16 个区域，每个区域用 1 个 (c,x,y,w,h) 去负责，就可以一次输出 16 个框，每个框是 1 个 (c,x,y,w,h)，如图所示：

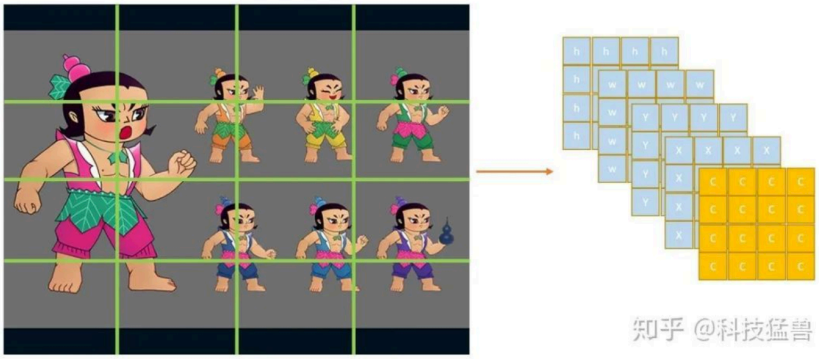

为什么这样子更优？因为 conv 操作是位置强相关的，就是原来的目标在哪里，你 conv 之后的 feature map 上还在哪里，所以图片划分为 16 个区域，结果也应该分布在 16 个区域上，所以我们的结果 (Tensor) 的维度 size 是：(5,4,4)。

那现在你可能会问：c 的真值该怎么设置呢？

答：看葫芦娃的大娃，他的脸跨了 4 个区域 (grid)，但只能某一个 grid 的 c=1，其他的 c=0。那么该让哪一个 grid 的 c=1 呢？就看他的脸的中心落在了哪个 grid 里面。根据这一原则，c 的真值为下图 7 所示：

图7：c的label值

但是你发现 7 个葫芦娃只有 6 个 1，原因是某一个 grid 里面有 2 个目标，确实如此，第三行第三列的 grid 既有水娃又有隐身娃。这种一个区域有多个目标的情况我们目前没法解决，因为我们的模型现在能力就这么大，只能在一个区域中检测出一个目标。改进方法后面讨论

总之现在我们设计出了模型的输出结果，那距离完成模型的设计还差一个损失函数，那 Loss 咋设计呢？看下面的伪代码：

```
loss = 0
for img in img_all:
    for i in range(3):
```

```
    for j in range(4):
        loss_ij = lamda_1*(c_pred-c_label)**2 + c_label*(x_pred-x_label)**2 +\
                  c_label*(y_pred-y_label)**2 + c_label*(w_pred-w_label)**2 + \
                  c_label*(h_pred-h_label)**2
        loss += loss_ij
loss.backward()
```

遍历所有图片，遍历所有位置，计算 loss。

现在回到刚才的问题：模型现在能力就这么大，只能在一个区域中检测出一个目标，如何改进？答案是：刚才区域是 4*4，可以变成 40*40，将区域变得更密集，就可以缓解多目标的问题，但是无法从根本上解决。

另一个问题，按上面的设计你检测得到了 16 个框，可是图片上只有 7 个葫芦娃的脸，怎么从 16 个结果中筛选出 7 个我们要的呢?

方法 1：聚类。聚成 7 类，在这 7 个类中，选择 confidence 最大的框。听起来挺好。问题是：2 个目标本身比较近聚成了 1 个类怎么办？如果不知道到底有几个目标呢？为何聚成 7 类？不是 3 类?

法 2：NMS(非极大值抑制)。2 个框重合度很高，大概率是一个目标，那就只取一个框。重合度的计算方法：交并比 IoU= 两个框的交集面积/两个框的并集面积。

具体算法：

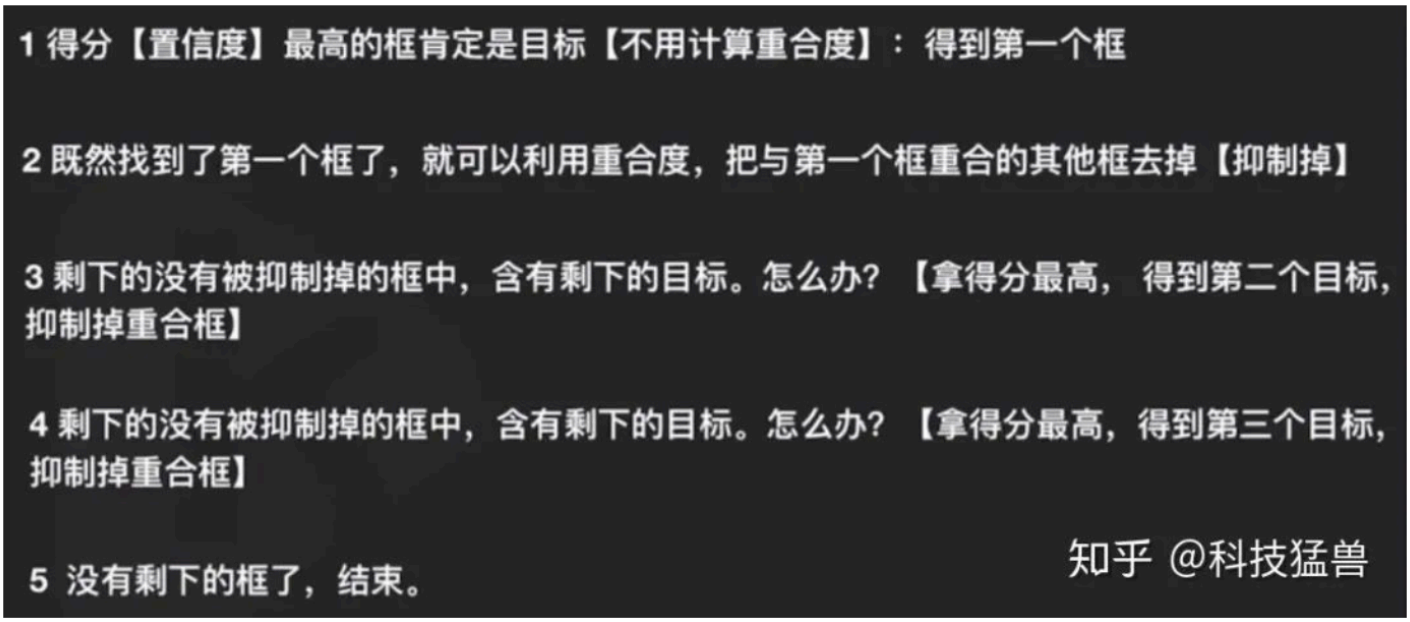

法 1 的 bug：2 个目标本身比较近怎么办？依然没有解决。

如果不知道到底有几个目标呢？NMS 自动解决了这个问题。

面试的时候会问这样一个问题：NMS 的适用情况是什么？

答：1 图多目标检测时用 NMS。

到现在为止我们终于解决了第 4 节开始提出的多个目标的问题，现在又有了新的需求：

需求 2：多类的目标怎么办呢？2 个类，one-hot 就是 [0,1],[1,0] 这样子，

References

[1] “你一定从未看过如此通俗易懂的 yolo 系列 (从 v1 到 v5) 模型解读 (上).” [Online]. Available: https://zhuanlan.zhihu.com/p/196241533